

Relatório de Projeto: Machine Learning


Desafio 04: Estimativa de Salários (Adult Income)

Integrantes: Rodrigo Shinji Yamashita (RA: 2001443) | Guilherme Dorce de Britto (RA: 1991866) | Matheus Gomes Pedroza (RA: 1998912)

Disciplina: Machine Learning - Teoria e Aplicado **Professora:** Ma. Nathália A. Lima


1. Análise Exploratória de Dados (EDA)

O conjunto de dados UCI Adult Income foi explorado para entender os determinantes da renda anual. Com aproximadamente 48.842 instâncias, a variável alvo (*income*) apresenta desbalanceamento: 76% da população ganha $\leq 50K$ contra 24% que ganham $>50K$.




Principais Insights:


- **Idade:** A idade atua como um marcador de experiência acumulada, com um aumento de renda conforme o envelhecimento com a probabilidade de pertencer à classe $>50K$ quando alcançar entre 38 e 50 anos | Observação: após os 60 anos há uma retração na proporção de altos salários.




- **Horas Trabalhadas:** As diferenças entre as cargas horárias não são uniformes entre os setores. No setor privado a carga horária média é de 40H independentemente do nível de educação. Já em cargos 'Self-employed-Inc' e setores que exijam algum tipo de pós-graduação, a média sobe para 48-52H semanais. O setor público (*State/Local gov*) mantém profissionais com alto nível de escolaridade sob rendas elevadas com cargas horárias mais estáveis.



- **Educação:** A variável 'education_num' mostrou-se um dos preditores mais fortes na classificação de renda, mostrando que a probabilidade de pertencer à classe de >50K aumenta a cada nível de escolaridade maior. Enquanto aqueles que possuem uma educação de nível médio (Edu-Num 9-10) permanecem majoritariamente na classe ≤50K, os indivíduos com nível a partir de um bacharelado superam de forma significativa a média de renda da base.



- **Capital Gain:** A maioria da base de dados possui valor zero para essa variável, mas a pequena parte da população que possui investimentos que geram ganhos de capital tem uma probabilidade maior de pertencer à classe >50K.



2. Pré-processamento e Engenharia de Features

As seguintes etapas foram realizadas para preparar os dados:

1. **Limpeza:** Remoção da coluna 'fnlwgt' (não informativa) e tratamento de valores ausentes (?).
2. **Codificação:** Variáveis categóricas foram transformadas via One-Hot Encoding e variáveis binárias via Label Encoding.
3. **Divisão Estratificada:** Separação inicial em conjuntos de Treino, Validação e Teste Final, mantendo de forma estrita a proporção original das classes (76% vs 24%).
4. **Escalação com Correção de Data Leakage:** Aplicação do StandardScaler realizada após a separação dos dados. O ajuste do escalador (fit_transform) foi feito exclusivamente nos dados de treino. A transformação (transform) foi aplicada nos dados de validação e teste separadamente, garantindo que o modelo não sofresse com vazamento de informações futuras.

3. Desempenho dos Modelos

Para garantir a confiabilidade dos resultados e diminuir o risco de overfitting, a avaliação não se limitou a um único treino/teste. Foi aplicada a técnica de **Validação Cruzada Estratificada (Stratified K-Fold) com k=5** para validar a performance e estabilidade dos modelos nos dados de treino. Essa abordagem foi escolhida devido ao desbalanceamento das classes (76% vs 24%):


- O conjunto de dados foi dividido em 5 partes ("folds"). Em cada rodada, o modelo treinou em 4 partes e testou na 5ª, assegurando assim que a dobra (fold) mantenha a proporção original de indivíduos com renda superior e inferior a 50K, evitando que o modelo fosse treinado ou testado em subconjuntos tendenciosos.

Descrição Técnica dos Modelos Treinados

1. **Regressão Logística:** Modelo linear que tenta encontrar uma fronteira de decisão (linha ou hiperplano) que separa quem ganha mais ou menos de 50K.


- **Comportamento:** Apresentou desempenho sólido (85,3% de acurácia média na validação cruzada).
- **Ponto Forte:** É um modelo altamente interpretável; os coeficientes nos dizem exatamente quanto cada ano de estudo ou cada dólar de ganho de capital aumenta a chance de alta renda.

- **Limitação:** Tem dificuldade em capturar interações complexas (ex: o efeito da idade pode ser diferente dependendo do tipo de ocupação).




2. Random Forest: Modelo pertencente à categoria de Ensemble Learning (Aprendizado em Conjunto), cria centenas de árvores de decisão, onde cada árvore vota na classe final.

- **Comportamento:** Apresentou a menor acurácia média (84,52%) e a maior variabilidade (desvio padrão de 0,0044).
- **Ponto Forte:** É excelente para lidar com dados brutos e variáveis categóricas sem precisar de muitos ajustes, além de ser resistente a outliers.
- **Limitação:** Como as árvores são criadas de forma independente, ele pode ser menos eficiente que o Gradient Boosting em aprender nuances muito específicas e erros residuais dos dados de censo.



3. Gradient Boosting Classifier: Modelo Ensemble que cria uma árvore por vez com o objetivo de corrigir especificamente os erros cometidos pela árvore anterior.

- **Comportamento:** Modelo com maior nível de acurácia média (86,40% na validação cruzada) e o mais estável (menor desvio padrão do projeto, estabelecido em 0,0015). Ele conseguiu "lapidar" o aprendizado, focando nos casos mais difíceis de classificar.
- **Ponto Forte:** Extremamente eficiente para capturar relações não-lineares e interações complexas entre as variáveis (como a combinação de estado civil, escolaridade e horas trabalhadas).
- **Limitação / Conclusão:** Oferece o melhor equilíbrio entre sensibilidade (identificar quem ganha muito) e especificidade (não classificar erroneamente quem ganha pouco).



A tabela abaixo resume os resultados obtidos com os dados corrigidos:

Modelo	Acurácia Média	Desvio Padrão	Precisão (Média)	Recall (Média)	F1-Score	AUC-ROC
Gradient Boosting	0.8640	0.0015	0.7822	0.6091	0.6849	0.9199
Regressão Logística	0.8529	0.0033	0.7410	0.5988	0.6624	0.9078
Random Forest	0.8452	0.0044	0.7068	0.6238	0.6627	0.8837

4. Análise Comparativa e Conclusão

Melhor Modelo e Justificativa

O modelo **Gradient Boosting Classifier** foi selecionado como o mais adequado para o problema. Ele apresentou o melhor desempenho (0.8640 de acurácia), maior AUC-ROC (0.9199) e a maior estabilidade (menor desvio padrão de 0.0015), indicando alta capacidade de generalização. Esse desempenho superior deve-se à sua arquitetura de aprendizado sequencial, que ajusta os erros dos modelos anteriores para capturar relações não lineares complexas nos dados do censo.

A separação transparente entre o processo de seleção e avaliação foi otimizada utilizando a seguinte divisão de conjuntos:

- **Validação Cruzada:** Mitigou oscilações locais nas dobras de treino e avaliou a consistência interna dos modelos.
- **Conjunto de Validação:** Atuou como base intermediária isolada para a escolha definitiva do modelo e refino de parâmetros.
- **Conjunto de Teste Final:** Garantiu uma auditoria estatística cega e fidedigna sobre dados inéditos.

Feature Importance

As variáveis mais impactantes na predição foram o estado civil (Married-civ-spouse), ganho de capital (Capital Gain) e nível educacional (Education Num). Isso reforça que fatores socioeconômicos e de investimento são os principais divisores de renda no cenário estudado.

Interpretação de Impacto: Idade vs Educação

- **Impacto da Educação:** A cada incremento na variável 'education_num', observa-se um aumento linear na probabilidade de alta renda. O "salto" mais significativo ocorre com indivíduos que possuem Bacharelado, confirmando que o ensino superior é o divisor de águas no mercado de trabalho.
- **Impacto da Idade:** O modelo identificou um ciclo de vida profissional. A idade contribui positivamente para a renda até a faixa dos 45-50 anos. Após este ponto, o impacto tende a se estabilizar ou declinar levemente devido a transições de carreira ou aposentadorias.

Discussão de Viés

Observou-se que o modelo pode reproduzir vieses históricos presentes nos dados, especialmente relacionados a gênero e ocupação. É fundamental notar que a acurácia elevada não elimina a necessidade de uma análise ética sobre como essas variáveis influenciam as decisões automatizadas, pois o modelo poderia perpetuar desigualdades baseado em vieses de sexo e grupos minoritários somente baseado nos vieses sistêmicos dos dados de treinamento.